


King County Housing – Cluster-Analyse

Joshua Schulz-Andres - Marian Kästner - David Schneider

Agenda

- 01 **Aufgabenverständnis & Hypothese**
- 02 **Datenbasis & Datenverständnis**
- 03 **Datenbereinigung & neue Merkmale**
- 04 **Modelle & Ergebnisse des Clusterings**
- 05 **Business-Interpretation und Fazit**



A background image showing a group of business professionals in an office setting. A man in a dark suit and striped tie is on the left, gesturing with his hands. A woman in a grey blazer is in the center, holding a smartphone. Another person is partially visible on the right. They are gathered around a table with a tablet displaying a diagram, a laptop, and coffee cups.

Phase 1: Business Understanding

Welches Problem wollen wir lösen?

Die Aufgabe: Datengetriebene Käufersegmentierung

Aufgabe: Statt Häuser in feste Kategorien zu pressen, gruppiert das Modell Häuser mit ähnlichen Eigenschaften und deckt so datengestützte Käufersegmente auf



Einsatzbereich

- Immobilienvermarktung und Marktsegmentierung, um:
 - die richtige Zielgruppe je Immobilie zu finden
 - Angebote zuzuschneiden
 - Marketingbudget effizient zu verteilen



Art der Aufgabe

- Mustererkennung & Clustering
- Keine vordefinierten Labels (Single, Familie) beim Training
- Label später bei Validierung
- unüberwachtes Lernen
- Verzicht auf starre Vorurteile



Merkmale

- bedrooms, sqft_living, price, grade, condition, ...
- Die inhaltliche Bedeutung eines Clusters (kleine, teure Singlewohnung oder großes Familienhaus) interpretieren wir erst nach dem Training

Unsere Hypothese

H1

Die Eignung einer Immobilie für **Familien** wird primär durch das Vorhandensein von mindestens 3 Schlafzimmern und einer signifikanten Außenfläche definiert. Wir nehmen an, dass es eine starke positive Korrelation zwischen der Hausgröße und der Anzahl der Schlafzimmer gibt, welches das Familien-Segment abgrenzt.

H2

Der **Luxusmarkt** (die oberen 5 % der Immobilienpreise) wird nicht allein durch die bloße Wohnfläche bestimmt, sondern durch exklusive qualitative Merkmale. Wir gehen davon aus, dass Immobilien mit Wasserblick oder einer sehr hohen Bauqualität überproportional oft in dieses Hochpreissegment fallen, unabhängig von der reinen Zimmeranzahl.

H3

Singles bevorzugen kleinere, pflegeleichtere Immobilien in bestimmten in städtischen Lagen. Wir nehmen an, dass Immobilien mit 1 bis 2 Schlafzimmern im Durchschnitt einen deutlich kleineren Grundstücksanteil haben und sich auf spezifische Postleitzahlengebiete konzentrieren, was auf eine urbane, verdichtete Wohnform hindeutet.

Unsere Hypothese

H1

Die Eignung einer Immobilie für **Familien** wird primär durch das Vorhandensein von mindestens 3 Schlafzimmern und einer signifikanten Außenfläche definiert.

Wir nehmen an, dass es eine starke positive Korrelation zwischen der Hausgröße und der Anzahl der Schlafzimmer gibt, welches das Familien-Segment abgrenzt.



Unsere Hypothese

H1

Die Eignung einer Immobilie für **Familien** wird primär durch das Vorhandensein von mindestens 3 Schlafzimmern und einer signifikanten Außenfläche definiert.

Wir nehmen an, dass es eine starke positive Korrelation zwischen der Hausgröße und der Anzahl der Schlafzimmer gibt, welches das Familien-Segment abgrenzt.

Familien Definition (accessus-immobilien):

- **Lage:** „während eine Immobilie im Grünen vor allem Familien“
- **Größe:** „während größere Häuser oder Wohnungen Familien ansprechen“
- **Beruf und Einkommen:** „während Familien mehr Platz und eine ruhige Umgebung bevorzugen“
- **Weiteres:** „Häuser oder Wohnungen mit mehreren Zimmern, Gartenzugang und in der Nähe von Schulen“



Unsere geschärfte Hypothese


Die Eignung einer Immobilie für **Familien** wird primär durch das Vorhandensein von mindestens 3 Schlafzimmern und einer signifikanten Außenfläche definiert.
Wir nehmen an, dass es eine starke positive Korrelation zwischen der Hausgröße und der Anzahl der Schlafzimmer gibt, welches das Familien-Segment abgrenzt.




Die Eignung einer Immobilie für **Familien** zeichnet sich durch ausreichende Hausgröße, mehrere Schlafzimmer, überdurchschnittlicher Grundstücksgröße, Gartenzugang bzw. eine grüne Lage sowie eine ruhige, wenig verdichtete Umgebung aus. Die Nähe zu Schulen ist ebenfalls ein wesentliches Merkmal.

Die Daten untersuchen


Datenbasis





House Sales in King County, USA




Datenverständnis



Datenverständnis



Datenverständnis



Günstigstes Haus



75.000\$



Mittelwertiges Haus




450.000\$



Teuerstes Haus



7.700.000\$



Phase 3: Data Preparation

Die Daten bereinigen und neue Features erstellen

Datenbereinigung

„Garbage in, Garbage out“ eine fehlerhafte Datenbasis würde die gesamte Marketingstrategie auf Sand bauen

DATENSÄTZE

21.613



21.420

bereinigte, verlässliche
Hausverkäufe

Über 99 % der
Originaldaten bleiben
erhalten, akribisch veredelt
statt pauschal verworfen



Datenfehler bereinigt

Offensichtliche Tippfehler korrigiert (z. B. ein Haus mit fälschlich 33 statt 3 Schlafzimmern) und unrealistische Werte wie 0 Badezimmer entfernt



Dubletten entfernt

Doppelt erfasste Immobilien herausgefiltert, um eine künstliche Verzerrung der Marktanteile zu verhindern



Mathematisch geglättet

Extreme Preissprünge und schiefe Verteilungen austariert, damit der Algorithmus ein faires, unverzerrtes Bild des Gesamtmarktes erhält

Häuser nach ihren echten Genen bündeln

Statt Immobilien nach Bauchgefühl zu sortieren, sucht der Algorithmus nach echten, tieferliegenden Ähnlichkeiten

- Die 4 Kernmerkmale unseres Markt Scans
- Bewusst schlank gehalten, damit der Algorithmus nach reinen wesentlichen Ähnlichkeiten sucht



Zimmeranzahl

Bedrooms, wie viel Platz bietet das Haus für Familien?



Grundstücksfläche

sqft_lot (später log_lot), wie viel eigenen Freiraum gibt es?



Zustand

Condition, in welchem Erhaltungszustand ist die Immobilie?



Luxus-Faktor (neues Feature)

luxury_score, das mathematische Premium Merkmal der Immobilie, bestehend aus View und Grade.

Phase 4: Modeling & Evaluation

The background of the slide features a blurred image of a data visualization. It includes several orange vertical bars of varying heights, suggesting a bar chart. Overlaid on these bars is a white line graph with circular markers at each data point. Some of the data points are labeled with numerical values: 183.102, 154.178, and 245.5. The overall aesthetic is professional and data-oriented, with a dark background that makes the orange and white elements stand out.

Aus den Daten Wissen ziehen

Drei Gruppierungs Algorithmen

Statt uns auf ein Verfahren zu verlassen, ließen wir 3 gängige Gruppierungs Algorithmen gegeneinander antreten


	Trennschärfe (saubere Trennung)		Überlappung (kompaktere Gruppen)	
	>0,50	gut	<1,0	gut
	0,25–0,50	akzeptabel	1,0–1,5	akzeptabel
	< 0,25	schwach	>1,5	schwach
Hierarchisches Clustering	2 <i>Kluster</i>	0,420	8 <i>Kluster</i>	0,991
K-Means	18 <i>Kluster</i>	0,413	6 <i>Kluster</i>	0,931
Gaussian Mixture	18 <i>Kluster</i>	0,290	4 <i>Kluster</i>	1,472

Hierarchisches Clustering und K-Means trennen die Gruppen am saubersten und halten sie zugleich kompakt, Gaussian Mixture fällt bei beiden Kennzahlen deutlich ab.


Das Ergebnis: 5 Cluster

k=5 trennt die Gruppen sauber genug und bleibt für die Vermarktung handhabbar


Gewählt



Warum nicht mehr Cluster?



k=6, leicht schlechtere Trennschärfe, schon zwei Splittergruppen



k=18, höchster Score, viele Cluster tendieren negativbereich

- **Statistisch gleichwertig**
(k=5 und k=6 sind fast gleichwertig, 5 ist ein wenig besser)
- **Grenzfälle offen ausgewiesen**
(Cluster 0/4 bleibt eine gemischte Restgruppe)

Bewusste Entscheidung: 5 Segmente



Zu grob oder zu fein hilft niemandem

- rechnerisch trennt das hierarchische am saubersten
 - 2 Cluster für gezieltes Marketing zu grob
- K-Means erreicht Bestwert bei 18 kleinstclustern
 - Je Cluster nur eine Handvoll Immobilien enthalten
- Wir haben uns deshalb bewusst für fünf Segmente entschieden
 - 3 tragende Segmente und 2 kleine Randgruppen
 - Bei 2 Randgruppen (Cluster 0 und 4) passen 12% der Punkte eigentlich besser in ein Nachbar Cluster



Der Robustheits-Test

Damit die Segmente kein Zufallsprodukt eines einzelnen Rechenlaufs sind, haben wir das Modell fünfzigmal mit unterschiedlichen Startpunkten neu trainiert

100 %

durchschnittliche Übereinstimmung über 50 Testläufe (Minimum: 99,9 %)

→ *Dieselben fünf Segmente entstehen bei jedem Durchlauf erneut.*

Das Ergebnis: 5 Cluster



1.605 Objekte 7,5 % (davon 12,0 % negativ)

Der Luxury Score ist klar überdurchschnittlich

5.767 Objekte 27 %

Der Zustand (condition) in diesem Cluster liegt deutlich über dem Durchschnitt, während alles andere darunter liegt

5.093 Objekte 24 %


Die Zimmer Anzahl (Anzahl der Schlafzimmer) ist klar überdurchschnittlich

7.237 Objekte 34 %

Die Eigenschaften sind alle unterdurchschnittlich.

1.718 Objekte 8 % (davon 12,2% negativ)

Der log_lot Score ist klar überdurchschnittlich

An aerial photograph of the Chicago skyline, showing a dense cluster of skyscrapers. The Lake Michigan is visible on the left side of the image. The sky is filled with soft, white clouds, and the overall lighting suggests a bright, slightly hazy day. The text "Business Interpretation" is overlaid in the center of the image in a large, white, sans-serif font.

Business Interpretation

Was ist mit dem Wissen anzufangen?

BUSINESS INTERPRETATION

Das Ergebnis: 5 Cluster



Die Segmente in Zahlen

	C0	C1	C2	C3	C4
Anzahl	1.605	5.767	5.093	7.237	1.718
Schlafzimmer	3,7	3,2	4,3	2,7	3,5
Wohnfläche (sqft)	3.043	1.779	2.611	1.598	2.689
Grundstück (sqft)	16.311	8.732	8.272	6.367	92.725
Zustand (1–5)	3,5	4,3	3,1	3,0	3,3
Distanz zum Zentrum	0,17	0,18	0,22	0,18	0,32
Preis \$ (Ø)	1,03 Mio	480 Tsd	601 Tsd	417 Tsd	637 Tsd

C2 und C4 sind unsere Familien Kandidaten

- viele Zimmer, großes Haus
- viel Grundstückfläche, viele Zimmer, großes Haus, Distanz zum Zentrum

BUSINESS INTERPRETATION

Familiensegment 5 Cluster Profilierung

Die Eignung einer Immobilie für **Familien** zeichnet sich durch ausreichende Hausgröße, mehrere Schlafzimmer, überdurchschnittlicher Grundstücksgröße, Gartenzugang bzw. eine grüne Lage sowie eine ruhige, wenig verdichtete Umgebung aus. Die Nähe zu Schulen ist ebenfalls ein wesentliches Merkmal.



	C2	C4
Anzahl	5.093	1.718
Schlafzimmer	4,3	3,5
Wohnfläche (sqft)	2.611	2.689
Grundstück (sqft)	8.272	92.725
Zustand (1–5)	3,1	3,3
Distanz zum Zentrum	0,22	0,32
Preis \$ (Ø)	601 Tsd	637 Tsd

BUSINESS INTERPRETATION

Fazit

Wir haben nach Zimmerzahl, Grundstücksgröße, Ausstattung und Zustand segmentiert. Anschließend haben wir die Segmente anhand weiterer Merkmale beschrieben. Zwei Segmente entsprechen dem Profil, das unsere Hypothese für familientaugliche Immobilien beschreibt



Handlungsempfehlung ans Marketing-Team

Segmentbezogenes Targeting & Kanalsteuerung

- Familien-Segmente: Meta Ads, lokale Familienmagazine
- Premium-Segment: Architektur- & Premium-Magazine
- Urbane Einsteiger & Budget: Socialmedia Ads, Immobilienportale

Zielgruppengerechtes Homestaging & Bildsprache

- C2/C4 (Familien): Bildfokus auf den Garten, helle Kinderzimmer und funktionale Gemeinschaftsräume
- C0 (Luxus): Detailaufnahmen hochwertiger Materialien, Architektur-Perspektiven und Abendstimmungs-Aufnahmen

Effiziente Budget-Allokation

- 50% des Budgets fließen in die volumensstarken Familien-Cluster (C2 & C4)
- 30% des Budgets werden zielgerichtet für ertragsstarke Luxus-Objekte (C0) reserviert.
- 20% des Budgets laufen über automatisierte, kostengünstige Performance-Ads für Einsteiger-Objekte (C1 & C3)

Daten Roadmap – Welche Daten uns noch fehlen & Potenziale

Erweiterung der Datenbasis

Analyse: Unsere aktuellen 5 Cluster trennen Raumgröße, Luxurösität, Zustand und Preis. Um den tatsächlichen Wohn- & Lebenswert noch präziser abzubilden, empfehlen wir die Anbindung externer Open-Data-Schnittstellen

1. Bildungs- & Schul-Infrastruktur:

- Fehlender Faktor: Exakte Schulbezirke, Schulqualität & Fußweg zu Grundschulen
- Business Nutzen: Für die Familien Segmente kann die Schulnähe ein Kaufgrund sein

2. Sicherheits- & Kriminalitätsindizes:

- Fehlender Faktor: Objektive Mikrolagen Sicherheit
- Business Nutzen: Sicherheitsindex als Kaufkriterium für Familien

3. Erholungsflächen & Mikrolage:

- Fehlender Faktor: Reale Erreichbarkeit von Grünflächen, Lärmbelastung & Baumbestand
- Business-Nutzen: Validierung der „grünen Lage“ und möglicher zusätzlicher Faktor für Cluster 2 als Alternative zum großen Garten

<https://data-seattlecitygis.opendata.arcgis.com/datasets/seattle-public-schools-sites-2023-2024/>
https://data-seattlecitygis.opendata.arcgis.com/datasets/b6de4b1fca644618a60c2a72cbdbbfe5_0/
<https://www.kaggle.com/datasets/sohier/seattle-police-department-911-incident-response>


https://data-seattlecitygis.opendata.arcgis.com/datasets/462a18bf1f9f459eb7fd8ea08c843880_0/
<https://data-seattlecitygis.opendata.arcgis.com/maps/9baab63b52df417a9b2a168e3f288b1b>

Die Segmente auf der Landkarte

Jeder der 21.420 Punkte ist anklickbar – ein Blick zurück auf die reale Geografie, die der Algorithmus nie gesehen hat

Als letzten Test übertragen wir die fünf Segmente zurück auf eine echte Karte von Seattle. Jedes Haus erscheint als farbiger Punkt an seiner tatsächlichen Adresse – eingefärbt nach seinem Segment. Per Klick auf einen Punkt öffnet sich der Original-Datensatz: Preis, Postleitzahl, Zimmerzahl und Luxus-Score des jeweiligen Hauses.

Zur Interaktion: anklicken für Objektdetails, zoombar und verschiebbar wie eine normale Karte.



Github Repo

https://github.com/Davido2909/DDM_Meilensteine/